Double descent nei modelli lineari

Teoria per l'Assignment 4 (SMML 2025/26, prof. Cesa-Bianchi)

Filippo Ferroni

Versione 4, 25 ottobre 2026

Come usare questo documento. Leggilo in circa 40 minuti. Le sezioni 2–6 sono la teoria minima da saper spiegare all'orale. La sezione 7 collega la teoria all'estensione con la gradient descent, la sezione 8 descrive cosa ci aspettiamo di vedere nei grafici, la sezione 9 il disegno degli esperimenti. In fondo: domande d'orale con risposta e soluzioni delle domande di verifica. Per ogni affermazione indico la fonte; quando un concetto **non** è nei materiali del corso del corso (slide 1–15 di Cesa-Bianchi) lo segnalo esplicitamente come fonte esterna.

Indice

1 Notazione e corrispondenze **1**

2 Setup statistico: rischio, errore di training, errore di test **1**

3 Least squares con $d \leq m$: la formula delle slide **2**

4 Least squares con $d > m$: la soluzione a minima norma **2**
4.1 Perché la formula delle slide non funziona più . . . 3
4.2 Infinite soluzioni che interpolano . . . 3
4.3 Quale scegliere: la soluzione a minima norma . . . 3
4.4 Una formula unica: la pseudo-inversa . . . 3
4.5 Esempio numerico minimo . . . 3

5 Perché il test error esplode a $d \approx m$ **4**
5.1 Intuizione con un esempio 2×2 . . . 4
5.2 Versione generale con gli autovalori . . . 4
5.3 Una formula esatta per il regime classico (facoltativa) . . . 4

6 Ridge regression **5**
6.1 Formula . . . 5
6.2 Perché elimina il picco . . . 5
6.3 Il prezzo: bias . . . 5
6.4 Calcolo in pratica . . . 5
6.5 Come scegliere α senza data leakage . . . 5

7 Collegamento con la gradient descent (estensione) **6**

8 Cosa ci aspettiamo nei grafici **6**
8.1 La curva a U classica e il double descent . . . 6
8.2 Grafici previsti . . . 6

9 Disegno degli esperimenti (anteprima) 7
9.1 Dataset sintetico: label lineari rumorose 7
9.2 Dataset reale con feature casuali 7
9.3 Regole contro il data leakage 7

10 Domande d'orale probabili, con risposta breve 7

11 Soluzioni delle domande di verifica 8

12 Fonti 8

1 Notazione e corrispondenze

Concetto	Corso (slide 9)	Assignment / paper	Codice
numero di esempi di training	m	n	`m`
numero di feature (complessità)	d	d (assignment) / N (paper)	`d`
design matrix	$X \in \mathbb{R}^{m \times d}$		`X`
etichette	$y \in \mathbb{R}^m$		`y`
parametro ridge	α	λ (altri testi)	`alpha`
soglia di interpolazione	$d = m$	$N = n$	

Attenzione: nel paper d è la dimensione dell'*input* x, mentre il numero di feature/parametri è N e i campioni sono n (p. 2 e p. 4).

Nel report scriveremo una volta sola: "seguiamo la notazione del corso; il numero di esempi n dell'assignment corrisponde a m". Le righe di X sono gli esempi: $X^\top = [x_1, \dots, x_m]$ (slide 9, p. 5). Un predittore lineare per la regressione è $h(x) = w^\top x$ con $w \in \mathbb{R}^d$ (slide 9, p. 1 e p. 4). L'intercetta si gestisce aggiungendo una feature costante pari a 1 (slide 9, p. 1) oppure centrando i dati.

2 Setup statistico: rischio, errore di training, errore di test

Fonte: slide "4. statRisk" (p. 1–4) e "1. intro" (p. 3–5).

- Ogni esempio (x, y) è estratto in modo indipendente da una distribuzione $\mathcal{D}$ fissata ma sconosciuta (statRisk, p. 1). Training set e test set sono quindi campioni statistici.
- **Rischio statistico** di un predittore h rispetto alla loss ℓ (statRisk, p. 1): $\ell_{\mathcal{D}}(h) = \mathbb{E}\big[\ell(h(X), Y)\big]$. Per noi $\ell(\hat{y}, y) = (\hat{y} - y)^2$ e $h(x) = w^\top x$.
- **Predittore Bayes-ottimo** f^*: il migliore possibile data $\mathcal{D}$. Per la square loss $f^*(x) = \mathbb{E}[Y \mid X = x]$ e il **rischio di Bayes** è la varianza condizionata attesa dell'etichetta (statRisk, p. 1–2). Nel nostro dataset sintetico, con $y = w^{\star\top} x + \varepsilon$ e rumore di varianza σ^2, il rischio di Bayes è proprio σ^2: **nessun modello può avere test error atteso sotto** σ^2. Lo useremo come linea di riferimento nei grafici.
- **Errore di training**: $\ell_S(h) = \frac{1}{m} \sum_{t=1}^{m} \ell(h(x_t), y_t)$; per noi $\ell_S(w) = \frac{1}{m} \|Xw - y\|^2$. ERM sceglie il predittore che lo minimizza (intro, p. 4).
- **Errore di test**: la stessa media calcolata su un test set S' indipendente; stima il rischio $\ell_{\mathcal{D}}(h)$, e per Chernoff–Hoeffding la stima è accurata quando il test set è grande (statRisk, p. 3–4). Il test set non va mai usato per addestrare né per scegliere iperparametri.

Overfitting e underfitting nel corso. Intro, p. 5: se l'algoritmo restituisce un predittore con training error alto è *underfitting*; con training error basso ma test error alto è *overfitting*. Il corso osserva che ci si aspetta overfitting quando la classe di predittori è troppo ricca rispetto a m ("$\log_2 |F| \gg m$", intro p. 5). **Il double descent è esattamente un caso in cui questa intuizione classica non basta**: per $d \gg m$ il training error è 0 ma il test error torna a scendere.

3 Least squares con $d \leq m$: la formula delle slide

Fonte: slide 9, p. 4–5.

Il predittore di regressione lineare è l'ERM rispetto alla square loss:

$$w_S = \operatorname*{argmin}_{w \in \mathbb{R}^d} \|Xw - y\|^2 .$$

$F(w) = \|Xw - y\|^2$ è convessa, quindi il minimo si trova dove il gradiente è nullo:

$$\nabla F(w) = 2X^\top (Xw - y) = 0 \quad \Longleftrightarrow \quad X^\top X\, w = X^\top y \qquad \text{(equazioni normali)}.$$

Se $X^\top X$ è invertibile:

$$\boxed{w_S = (X^\top X)^{-1} X^\top y}$$

Quando è invertibile? La slide dice: se e solo se $x_1, \ldots, x_m$ generano $\mathbb{R}^d$. Servono almeno d vettori per generare $\mathbb{R}^d$, quindi serve $m \geq d$.

Interpretazione geometrica. Il vettore delle predizioni sul training set è $Xw_S = X(X^\top X)^{-1} X^\top y = Py$, dove P è la proiezione ortogonale sullo spazio generato dalle colonne di X. Più feature aggiungiamo, più grande è quello spazio, più Py si avvicina a y: l'errore di training **non può aumentare** quando d cresce.

Il caso $d = m$. Se X è quadrata e invertibile, $w_S = X^{-1} y$ e $Xw_S = y$: errore di training esattamente 0. Il modello **interpola** già a $d = m$. Da qui il nome "soglia di interpolazione".

4 Least squares con $d > m$: la soluzione a minima norma

Fonte esterna (non nei materiali del corso): pseudo-inversa di Moore–Penrose, testi standard di algebra lineare (es. Strang, Introduction to Linear Algebra*, capitolo su pseudo-inversa e SVD); uso della soluzione a minima norma: Belkin et al. 2019, sez. 2 (p. 4: "quando il minimizzatore non è unico ... scegliamo quello con norma ℓ_2 minima") e p. 10 ("minimum norm linear regression in the feature space").*

4.1 Perché la formula delle slide non funziona più

$X^\top X$ è una matrice $d \times d$, ma il suo rango è uguale al rango di X, che è al massimo $\min(m, d) = m$. Se $d > m$ allora $\operatorname{rank}(X^\top X) \leq m < d$: la matrice è **singolare** e $(X^\top X)^{-1}$ non esiste. Equivalentemente: m vettori non possono generare $\mathbb{R}^d$ se $m < d$.

4.2 Infinite soluzioni che interpolano

Con $d > m$ (e righe di X linearmente indipendenti, il caso tipico con dati continui), il sistema $Xw = y$ ha m equazioni e d incognite: ha **infinite** soluzioni esatte. Se w_0 è una soluzione, lo è anche $w_0 + z$ per ogni z nel nucleo di X ($Xz = 0$), che ha dimensione $d - m$. Tutte hanno errore di training 0.

4.3 Quale scegliere: la soluzione a minima norma

$$\boxed{w^+ = \operatorname{argmin}\{\|w\| : Xw = y\} = X^\top (XX^\top)^{-1} y}$$

Verifica che interpola: $Xw^+ = XX^\top (XX^\top)^{-1} y = y$. ($XX^\top$ è $m \times m$ e invertibile se le righe di X sono indipendenti.)

Perché ha norma minima (dimostrazione breve, da saper fare). $w^+ = X^\top a$ con $a = (XX^\top)^{-1} y$, quindi w^+ è combinazione lineare delle righe di X. Ogni altra soluzione è $w = w^+ + z$ con $Xz = 0$, cioè z è ortogonale a tutte le righe di X, e quindi a w^+. Per Pitagora:

$$\|w\|^2 = \left\|w^+\right\|^2 + \|z\|^2 \geq \left\|w^+\right\|^2 .$$

4.4 Una formula unica: la pseudo-inversa

La pseudo-inversa X^+ si calcola dalla SVD $X = U\Sigma V^\top$: $X^+ = V\Sigma^+ U^\top$, dove Σ^+ inverte i valori singolari non nulli e lascia a zero gli altri. Vale:

- se $d \leq m$ e X ha rango pieno: $X^+ y = (X^\top X)^{-1} X^\top y = w_S$ (la formula delle slide);
- se $d > m$ e X ha rango m: $X^+ y = X^\top (XX^\top)^{-1} y = w^+$.

Quindi in numpy basta `w = np.linalg.pinv(X) @ y` per **tutti** i d. È algebra lineare, non un "fit" di libreria, quindi rispetta il vincolo "from scratch" (FAQ dell'assignment, p. 16).

Note numeriche (importanti per il codice).

- Non usare `np.linalg.inv(X.T @ X)`: formare $X^\top X$ eleva al quadrato il numero di condizionamento, e vicino a $d = m$ i risultati diventano numericamente inaffidabili.
- `np.linalg.pinv` azzera solo i valori singolari sotto una soglia minuscola (`rcond`, circa 10^{-15} relativo al più grande). Vicino a $d = m$ i valori singolari piccoli *non* vengono azzerati: `pinv` non regolarizza, quindi il picco resta visibile. È il comportamento che vogliamo mostrare.

4.5 Esempio numerico minimo

$m = 1$, $d = 2$: un solo esempio $x = (1, 1)$, $y = 2$. Le soluzioni di $w_1 + w_2 = 2$ sono infinite: $(2, 0)$, $(0, 2)$, $(1, 1)$, $(3, -1)\ldots$ La soluzione a minima norma è $w^+ = x^\top (xx^\top)^{-1} y = (1, 1) \cdot \frac{2}{2} = (1, 1)$, con norma $\sqrt{2}$, contro norma 2 di $(2, 0)$. Distribuisce il peso in modo uniforme invece di "puntare tutto" su una feature.

5 Perché il test error esplode a $d \approx m$

Fonte: slide 9, p. 5: "quando $X^\top X$ è quasi singolare, w_S è molto sensibile a perturbazioni del training set. Questa instabilità aumenta l'errore di stima (varianza)". È l'aggancio al corso.

5.1 Intuizione con un esempio 2×2

$m = d = 2$, righe $x_1 = (1, 0)$, $x_2 = (1, \varepsilon)$ con ε piccolo (righe quasi parallele, X quasi singolare). Etichette $y = (1,\ 1{+}\delta)$, dove δ è un piccolo rumore. Risolvendo $Xw = y$: $w_1 = 1$ e $w_1 + \varepsilon w_2 = 1 + \delta$, quindi

$$w_2 = \delta / \varepsilon .$$

Con $\varepsilon = 0.01$ e un rumore $\delta = 0.1$, otteniamo $w_2 = 10$: un rumore piccolo produce un peso enorme. Su un nuovo punto, ad esempio $x = (0, 1)$, la predizione vale 10 invece di circa 0. È esattamente il picco.

5.2 Versione generale con gli autovalori

Siano $\lambda_1 \geq \cdots \geq \lambda_d \geq 0$ gli autovalori di $X^\top X$ e $v_1, \ldots, v_d$ gli autovettori (ortonormali). La soluzione a minima norma si scrive

$$w^+ = \sum_{i:\,\lambda_i > 0} \frac{v_i^\top X^\top y}{\lambda_i}\, v_i.$$

Supponiamo label lineari con rumore: $y = Xw^\star + \varepsilon$. La parte dovuta al rumore è $\sum_i \frac{v_i^\top X^\top \varepsilon}{\lambda_i} v_i$; ogni termine ha norma $\frac{|u_i^\top \varepsilon|}{\sqrt{\lambda_i}}$, con $u_i = Xv_i/\sqrt{\lambda_i}$ vettore unitario. **Il rumore viene diviso per $\sqrt{\lambda_i}$.**

- $d \ll m$: X è "alta e stretta", tutti gli autovalori sono grandi (circa m per feature standardizzate): il rumore viene smorzato.
- $d \approx m$: X è quasi quadrata e casuale, il più piccolo autovalore è vicinissimo a 0: il rumore viene amplificato, $\|w\|$ esplode, e con lui il test error.
- $d \gg m$: X è "larga", gli m autovalori non nulli tornano lontani da 0 e il rumore viene "spalmato" su molte direzioni: $\|w^+\|$ e il test error scendono. È la **seconda discesa**.

Fonte esterna (non nei materiali del corso): il comportamento del più piccolo autovalore di una matrice casuale in funzione di d/m è un risultato di random matrix theory (legge di Marchenko–Pastur). Non lo dimostriamo: lo mostriamo empiricamente plottando $\|w\|$ in funzione di d, che è più difendibile all'orale.

5.3 Una formula esatta per il regime classico (facoltativa)

Fonte esterna (non nei materiali del corso): Hastie, Montanari, Rosset, Tibshirani, "Surprises in high-dimensional ridgeless least squares interpolation", Annals of Statistics 2022.

Se $x \sim \mathcal{N}(0, I_d)$, $y = w^{\star\top} x + \varepsilon$ con rumore di varianza σ^2 e $d < m - 1$, allora

$$\mathbb{E}\big[\|w_S - w^\star\|^2\big] = \sigma^2 \frac{d}{m - d - 1},$$

che **diverge per** $d \to m - 1$. Non serve dimostrarla; è utile per dire all'orale che il picco non è un artefatto numerico ma un fenomeno statistico previsto dalla teoria.

6 Ridge regression

Fonte: slide 9, p. 5.

6.1 Formula

$$w_{S,\alpha} = \operatorname*{argmin}_{w \in \mathbb{R}^d} \|Xw - y\|^2 + \alpha \|w\|^2, \qquad \alpha > 0.$$

Gradiente: $2X^\top(Xw - y) + 2\alpha w = 0 \;\Rightarrow\; (X^\top X + \alpha I)\, w = X^\top y$, quindi

$$\boxed{w_{S,\alpha} = (\alpha I + X^\top X)^{-1} X^\top y}$$

6.2 Perché elimina il picco

Gli autovalori di $\alpha I + X^\top X$ sono $\alpha + \lambda_i \geq \alpha > 0$ (slide 9, p. 5): la matrice è sempre invertibile, per ogni d, anche $d > m$. Nella base degli autovettori:

$$w_{S,\alpha} = \sum_i \frac{v_i^\top X^\top y}{\lambda_i + \alpha} v_i.$$

Si divide per $\lambda_i + \alpha$ invece che per λ_i: anche quando $\lambda_i \approx 0$ il denominatore resta almeno α, quindi il rumore non può essere amplificato senza limite. Il picco si attenua o sparisce.

6.3 Il prezzo: bias

- $\alpha \to 0$: si ritrova la soluzione a minima norma w^+ (anche per $d > m$; nelle direzioni con $\lambda_i = 0$ il numeratore $v_i^\top X^\top y$ è 0). *Fatto standard, non nelle slide.*
- $\alpha \to \infty$: $w_{S,\alpha} \to 0$, il predittore ignora i dati (slide 9, p. 5: α controlla il bias).
- In mezzo: α scambia varianza (instabilità) con bias (sotto-adattamento). Con α troppo grande il test error sale *per tutti* i d.

Fonte: Belkin et al. 2019, p. 10: la regolarizzazione "può sia impedire l'interpolazione sia cambiare la capacità effettiva della classe, attenuando o mascherando il picco".
Fonte esterna (non nei materiali del corso): Nakkiran, Venkat, Kakade, Ma, "Optimal regularization can mitigate double descent", ICLR 2021: con α ottimale la curva del test error diventa monotona.

6.4 Calcolo in pratica

- Primale: `np.linalg.solve(X.T @ X + alpha * np.eye(d), X.T @ y)` (sistema $d \times d$).
- Duale, più economico per $d > m$: $w_{S,\alpha} = X^\top (XX^\top + \alpha I)^{-1} y$ (sistema $m \times m$). Le due forme coincidono perché $X^\top (XX^\top + \alpha I) = (X^\top X + \alpha I) X^\top$.
- `solve` è preferibile a calcolare l'inversa esplicita (più stabile e più veloce).

6.5 Come scegliere α senza data leakage

- Per il grafico principale: alcune curve con α fissi (es. $10^{-3}, 10^{-1}, 10$) accanto alla curva di minima norma. Nessuna scelta sui dati, nessun leakage.
- Se avanza tempo: α scelto per ogni d con un validation split (o K-fold cross-validation) ricavato **solo** dal training set (slide "6. crossVal", p. 2–3: tuning su validation set; p. 3–4: nested CV), come nel notebook `CrossValidation.ipynb` del prof. Il test set non si usa mai per scegliere.

7 Collegamento con la gradient descent (estensione)

Fonte: slide 10 (online gradient descent) per l'algoritmo; il risultato sulla minima norma è esterno (vedi sotto).

Gradient descent su $F(w) = \|Xw - y\|^2$ partendo da $w_1 = 0$:

$$w_{k+1} = w_k - \eta\, 2X^\top (Xw_k - y).$$

- Ogni aggiornamento è $X^\top(\dots)$, cioè una combinazione lineare delle righe di X. Partendo da 0, w_k resta sempre nello spazio delle righe.

- Con passo η abbastanza piccolo ($\eta < 1/\lambda_1$), per $d > m$ la GD converge a una soluzione che interpola e sta nello spazio delle righe: per la dimostrazione della Sezione 4.3, è proprio w^+.
- Fermarsi prima della convergenza (early stopping) ha un effetto simile alla ridge: le direzioni con λ_i piccolo sono le ultime a essere apprese, quindi il rumore lungo di esse non viene amplificato.

Fonte: bias implicito della GD verso la minima norma: Belkin et al. 2019, p. 11 ("SGD initialized at zero also converges to the minimum norm solution").

L'estensione si fa **solo** se report e repo sono completi.

8 Cosa ci aspettiamo nei grafici

8.1 La curva a U classica e il double descent

- **Regime classico** ($d < m$): il corso scompone il rischio di h_S in *errore di stima* (varianza) + *errore di approssimazione* (bias) + rischio di Bayes (statRisk, p. 4). Aggiungendo feature il bias scende ma la varianza sale; overfitting quando domina la varianza, underfitting quando domina il bias (statRisk, p. 6). Vicino a $d = m$ la varianza va a infinito: è la curva a U.
- **Soglia di interpolazione** ($d = m$): l'errore di training arriva a 0, il test error ha il picco.
- **Regime sovra-parametrizzato** ($d > m$): errore di training sempre 0, il test error scende di nuovo e può andare sotto il minimo del regime classico (paper, Fig. 1, p. 3). Spiegazione del paper (p. 3 e p. 6): oltre la soglia, classi più ricche contengono interpolanti di norma più piccola, cioè "più semplici" (rasoio di Occam); la norma è massima alla soglia e poi decresce (Fig. 2, p. 5). La teoria classica, che prevede solo la U, non spiega questa parte: è il punto del paper.

8.2 Grafici previsti

1. Errore di training e di test in funzione di d (minima norma), linea verticale a $d = m$, asse y logaritmico (il picco è di ordini di grandezza).
2. Sul sintetico, linea orizzontale al rischio di Bayes σ^2 (Sezione 2) come riferimento.
3. $\|w\|$ in funzione di d: deve avere il picco nello stesso punto (evidenza del meccanismo della Sezione 5).
4. Test error di minima norma e ridge (più valori di α) sullo stesso grafico.
5. Gli stessi grafici per il dataset reale, e un confronto tra i due dataset.

9 Disegno degli esperimenti (anteprima)

Rapporto con il paper. Il paper mostra il fenomeno con random Fourier features e random ReLU features (sez. 2 e App. C.1–C.2), reti neurali (sez. 2) e foreste/boosting (sez. 3), su MNIST e altri dataset di classificazione. Non contiene un esperimento di regressione lineare "pura", ma le random features sono addestrate con regressione lineare a minima norma nello spazio delle feature (p. 10): il nostro esperimento ne è la versione più semplice.

9.1 Dataset sintetico: label lineari rumorose

Fonte esterna (non nei materiali del corso): modello a "feature deboli": Belkin, Hsu, Xu, "Two models of double descent for weak features", 2019.

- $x \sim \mathcal{N}(0, I_D)$ con D grande (es. $D = 1000$), $y = w^{\star\top} x + \varepsilon$, rumore gaussiano.
- Il modello con complessità d usa solo le prime d feature. Per $d < D$ le feature non usate agiscono come rumore aggiuntivo (bias); per d grande il modello ha accesso a tutto il segnale.
- m fisso (es. $m = 100$), d da 1 a D, griglia più fitta intorno a $d = m$.
- Media (o mediana) su più ripetizioni con seed diversi, con banda di variabilità.

9.2 Dataset reale con feature casuali

- Un dataset di regressione con poche feature (es. California Housing, 8 feature, presente anche nel repo del prof).
- Per far crescere d oltre m: feature casuali $\phi(x) = \max(0, Wx)$ (ReLU) con W gaussiana fissata, oppure random Fourier features come nel paper. Il modello resta **lineare nei parametri** w. Il corso chiama questa idea *feature expansion*: aggiungere nuove feature costruite dalle originali per ridurre il bias dei predittori lineari (slide "11. kernels", p. 1).
- Sottocampioniamo m esempi di training (es. $m = 200$) e teniamo un test set separato.

9.3 Regole contro il data leakage

- Split train/test *prima* di qualunque pre-processing.
- Media e deviazione standard per standardizzare calcolate **solo** sul training set e applicate al test set.
- Le matrici casuali W non dipendono dai dati, quindi non creano leakage, ma vanno generate con seed fissato.
- Iperparametri (es. α) scelti solo con dati di training.

10 Domande d'orale probabili, con risposta breve

1. **Cos'è il double descent?** Il test error, in funzione della complessità, scende, risale fino a un picco alla soglia di interpolazione ($d = m$) e poi scende di nuovo nel regime sovra-parametrizzato.
2. **Perché il picco proprio a $d = m$?** Lì X è quasi quadrata, $X^\top X$ ha un autovalore quasi nullo, la soluzione divide il rumore per quell'autovalore e $\|w\|$ esplode (slide 9, p. 5 e Sezione 5).
3. **Perché il training error è 0 per $d \geq m$?** Con $d \geq m$ e righe indipendenti, $Xw = y$ ha almeno una soluzione esatta: il modello interpola.
4. **Che soluzione usi per $d > m$ e perché?** La minima norma $X^+ y$: è unica, interpola, ed è il limite della ridge per $\alpha \to 0$ e il punto a cui converge la GD partita da 0.
5. **Come hai calcolato X^+?** Con `np.linalg.pinv`, basata sulla SVD. È algebra lineare, non un fit.

6. **Cosa fa la ridge al picco?** Sostituisce λ_i con $\lambda_i+\alpha$ al denominatore: niente amplificazione del rumore, picco attenuato o eliminato, al costo di un po' di bias.

7. **Come hai scelto α?** Valori fissi a confronto, e/o validazione solo sul training set. Mai sul test.

8. **Come fai variare d sul dataset reale?** Con feature casuali; il modello resta lineare nei parametri.

9. **Come eviti il data leakage?** Split prima di tutto, statistiche di standardizzazione solo dal training, iperparametri solo dal training.

10. **Perché il double descent contraddice la teoria classica?** La teoria classica prevede che oltre un certo punto aumentare la complessità peggiori sempre la generalizzazione (curva a U). Nel regime $d > m$ succede il contrario.

11. **Punti deboli del tuo lavoro?** Modelli solo lineari; il dataset reale richiede feature casuali, quindi il risultato dipende da come le costruisci; poche ripetizioni per vincoli di tempo; scelta di m arbitraria.

11 Soluzioni delle domande di verifica

Prova a rispondere prima da solo, poi confronta.

Domanda 1. Perché per $d > m$ la formula $(X^\top X)^{-1}X^\top y$ non si può usare, e cosa calcola `pinv(X) @ y`?

Risposta. $X^\top X$ è $d \times d$ ma ha rango al massimo $m < d$, quindi è singolare e non invertibile (equivalentemente, m vettori non generano $\mathbb{R}^d$, slide 9 p. 4). Il sistema $Xw = y$ ha infinite soluzioni che interpolano. `pinv(X) @ y` restituisce quella di norma euclidea minima, $X^\top(XX^\top)^{-1}y$: è unica, sta nello spazio delle righe di X, e ogni altra soluzione ha norma maggiore (Pitagora). Per $d \leq m$ coincide con la formula delle slide.

Domanda 2. Perché la ridge non ha il picco a $d = m$?

Risposta. Nella soluzione di minima norma le componenti di y vengono divise per gli autovalori λ_i di $X^\top X$; a $d \approx m$ il più piccolo è quasi 0 e il rumore esplode. La ridge inverte $\alpha I + X^\top X$, i cui autovalori sono $\lambda_i + \alpha \geq \alpha > 0$ (slide 9 p. 5): il denominatore non scende mai sotto α, quindi $\|w\|$ e il test error restano limitati. Il prezzo è il bias: con α troppo grande $w \to 0$ e il modello sotto-adatta.

12 Fonti

- N. Cesa-Bianchi, slide "Introduction" (1. intro), p. 3–5; "Statistical learning" (4. statRisk), p. 1–6; "Hyperparameter tuning and risk estimates" (6. crossVal), p. 2–4; "Kernels" (11. kernels), p. 1.
- N. Cesa-Bianchi, slide "Linear predictors" (9. linear), versione del 10/02/2026, p. 4–5.
- N. Cesa-Bianchi, slide "Online Gradient Descent" (10. online), versione del 24/02/2026.
- M. Belkin, D. Hsu, S. Ma, S. Mandal, "Reconciling modern machine learning practice and the classical bias-variance trade-off", PNAS 2019 (arXiv:1812.11118). Versione arXiv v2 (10/09/2019); numeri di pagina riferiti a quel PDF.

- M. Belkin, D. Hsu, J. Xu, "Two models of double descent for weak features", 2019 (arXiv:1903.07571). *Esterna.*
- T. Hastie, A. Montanari, S. Rosset, R. Tibshirani, "Surprises in high-dimensional ridgeless least squares interpolation", Annals of Statistics 2022. *Esterna.*
- P. Nakkiran, P. Venkat, S. Kakade, T. Ma, "Optimal regularization can mitigate double descent", ICLR 2021. *Esterna.*
- Assignment "ML projects 25/26", Assignment 4 (p. 8–9) e FAQ (p. 16).